Linguaggi di Programmazione (Corso A)

Docente: Giovanni Semeraro

Il Modello di un Compilatore

Il Modello di un Compilatore

- La costruzione di un compilatore per un particolare linguaggio di programmazione è un'operazione abbastanza complessa.
- La complessità dipende principalmente dal linguaggio sorgente.

Compilatore

- Traduce il programma sorgente in programma oggetto.
- Esegue:
  - Analisi del programma sorgente;
  - Sintesi del programma oggetto.

Compilatore: modello funzionale

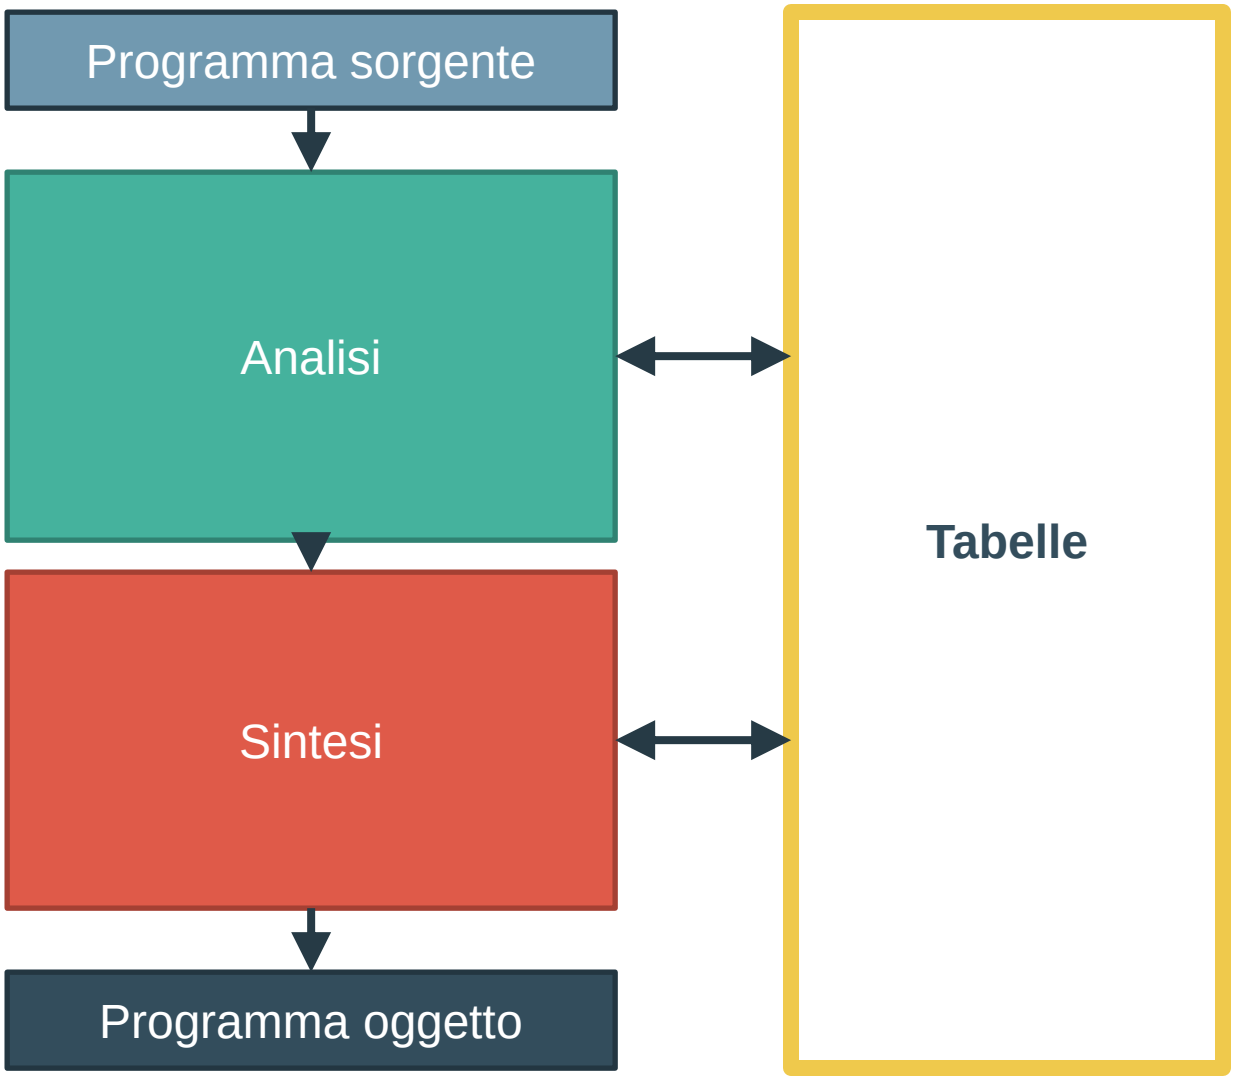

Compilatore: modello funzionale

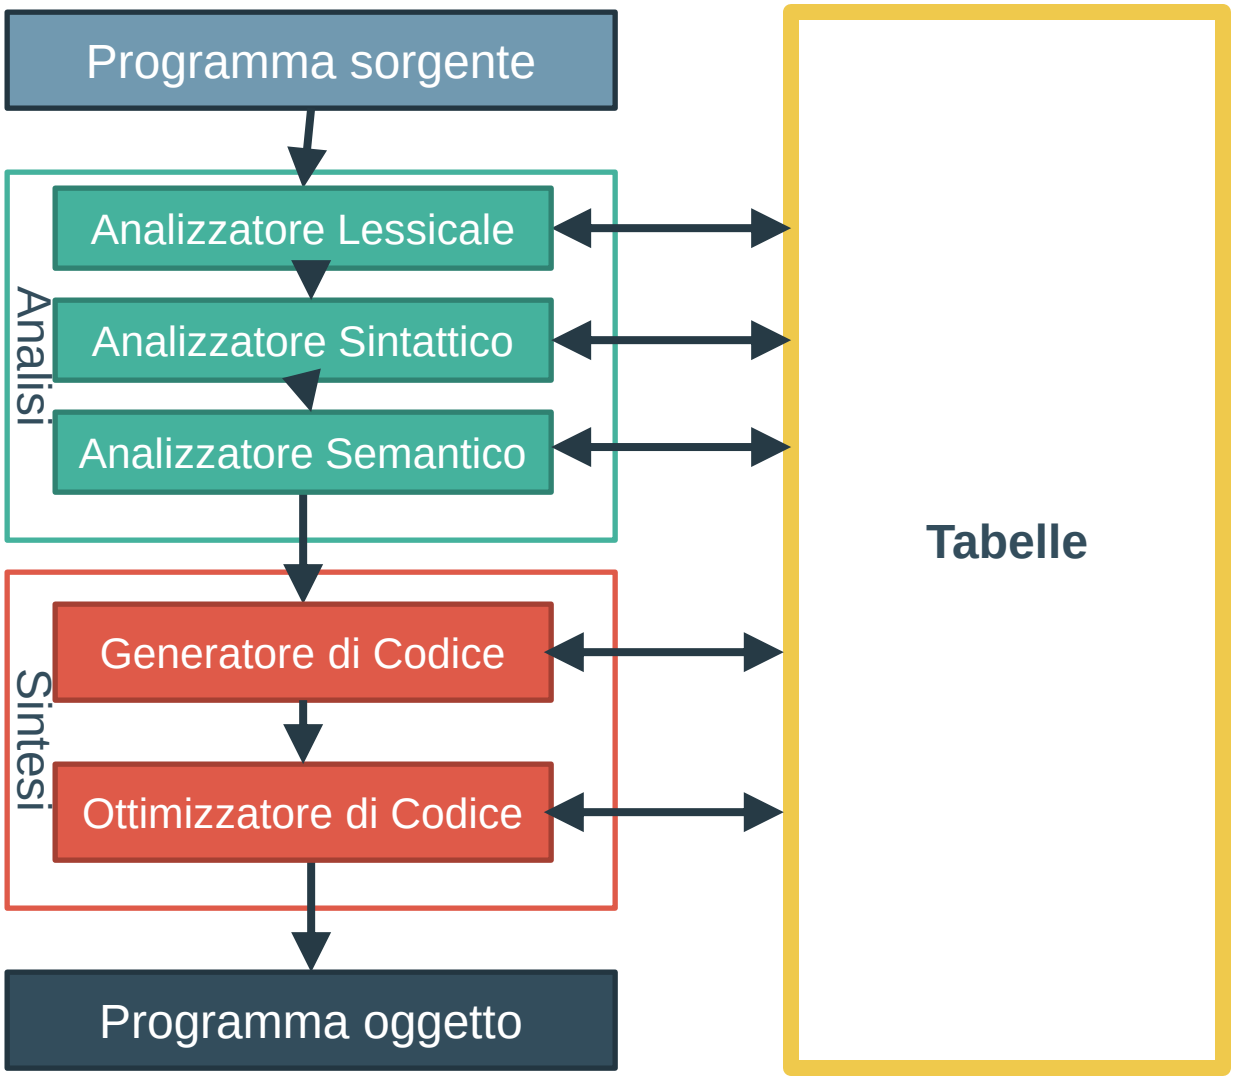

Programma sorgente

- È una stringa di simboli.
- Esempio

```
if A>B then X:=Y;
```

Analizzatore lessicale (scanner)

- Input: un programma sorgente
- Esamina il programma per individuare i simboli (token) che lo compongono classificando parole chiave, identificatori, operatori, costanti, ecc.
- Per ragioni di efficienza ad ogni classe di token è dato un numero unico che la identifica.
- Output: lista di token

Analizzatore lessicale (scanner)

- Esempio

```
if A>B then X:=Y;

IF          20
A           1
>           15
B           1
THEN        20
X           1
:=          10
Y           1
;           27
```

- Si noti che vengono ignorati spazi bianchi e commenti. Inoltre alcuni scanner inseriscono label, costanti e variabili in tavole appropriate.
- Un elemento della tavola per una variabile, ad esempio, contiene nome, tipo, indirizzo, valore e linea in cui è dichiarata.

Analizzatore lessicale (scanner)

- Esempio

Programma in input

```
x1:=a+bb*12;
x2:=a/2+bb*12;
```

Sequenza di token

“x1“	Id
“:=”	Op
"a"	Id
“+”	Op
"bb"	Id
“*”	Op
12	Lit
;	Punct
“x2”	Id
“:=”	Op
“a”	Id
"/”	Op
2	Lit
“+”	Op
"bb"	Id
“*”	Op
12	Lit
;	Punct

Analizzatore lessicale (scanner)

- Esempio

Programma in input

```
x1:=a+bb*12;
x2:=a/2+bb*12;
```

Sequenza di token

“x1“	Id
“:=”	Op
"a"	Id
“+”	Op
"bb"	Id
“*”	Op
12	Lit
;	Punct
“x2”	Id
“:=”	Op
“a”	Id
"/"	Op
2	Lit
“+”	Op
"bb"	Id
“*”	Op
12	Lit
;	Punct

Analizzatore lessicale (scanner)

- Esempio

Programma in input

```
x1:=a+bb*12;
x2:=a/2+bb*12;
```

Sequenza di token

“x1“	Id
“:=”	Op
"a"	Id
“+”	Op
"bb"	Id
“*”	Op
12	Lit
;	Punct
“x2”	Id
“:=”	Op
“a”	Id
"/”	Op
2	Lit
“+”	Op
"bb"	Id
“*”	Op
12	Lit
;	Punct

Analizzatore lessicale (scanner)

- Esempio

Programma in input

```
x1:=a+bb*12;
x2:=a/2+bb*12;
```

Sequenza di token

"x1"	Id
":="	Op
"a"	Id
"+"	Op
"bb"	Id
"*"	Op
12	Lit
;	Punct
"x2"	Id
":="	Op
"a"	Id
"/"	Op
2	Lit
"+"	Op
"bb"	Id
"*"	Op
12	Lit
;	Punct

Analizzatore lessicale (scanner)

- Esempio

Programma in input

```
x1:=a+bb*12;
x2:=a/2+bb*12;
```

Sequenza di token

"X1"	Id
":="	Op
"a"	Id
"+"	Op
"bb"	Id
"*"	Op
12	Lit
;	Punct
"X2"	Id
":="	Op
"a"	Id
"/"	Op
2	Lit
"+"	Op
"bb"	Id
"*"	Op
12	Lit
;	Punct

Analizzatore sintattico (parser)

- Input: lista di token
- Individua la struttura sintattica della stringa in esame a partire dal programma sorgente sotto forma di token.
- Identifica quindi espressioni, istruzioni, procedure.
- Output: albero sintattico

Analizzatore sintattico (parser)

- Esempio `ALFA1:=5+A*B`
- La stringa `5+A*B` è riconosciuta come `<espressione>`
- La stringa completa è riconosciuta come `<assegnazione>` in accordo alla regola sintattica:

`<assegnazione>::= <variabile> := <espressione>`

- In realtà si utilizza la stringa semplificata del tipo:

`id1:=c2+id3*id4`

con accesso alla rappresentazione generata dallo scanner.

Analizzatore sintattico (parser)

- Esempio `(A+B)*(C+D)`
- L'analisi produce le classi sintattiche:
  - `<fattore>`
  - `<termine>`
  - `<espressione>`
- Il controllo sintattico si basa sulle *regole grammaticali* utilizzate per definire formalmente il linguaggio.
- Durante il controllo sintattico si genera l'albero di derivazione (*albero sintattico*)

Analizzatore sintattico (parser)

- Esempio

```
(A+B)*(C+D)
```

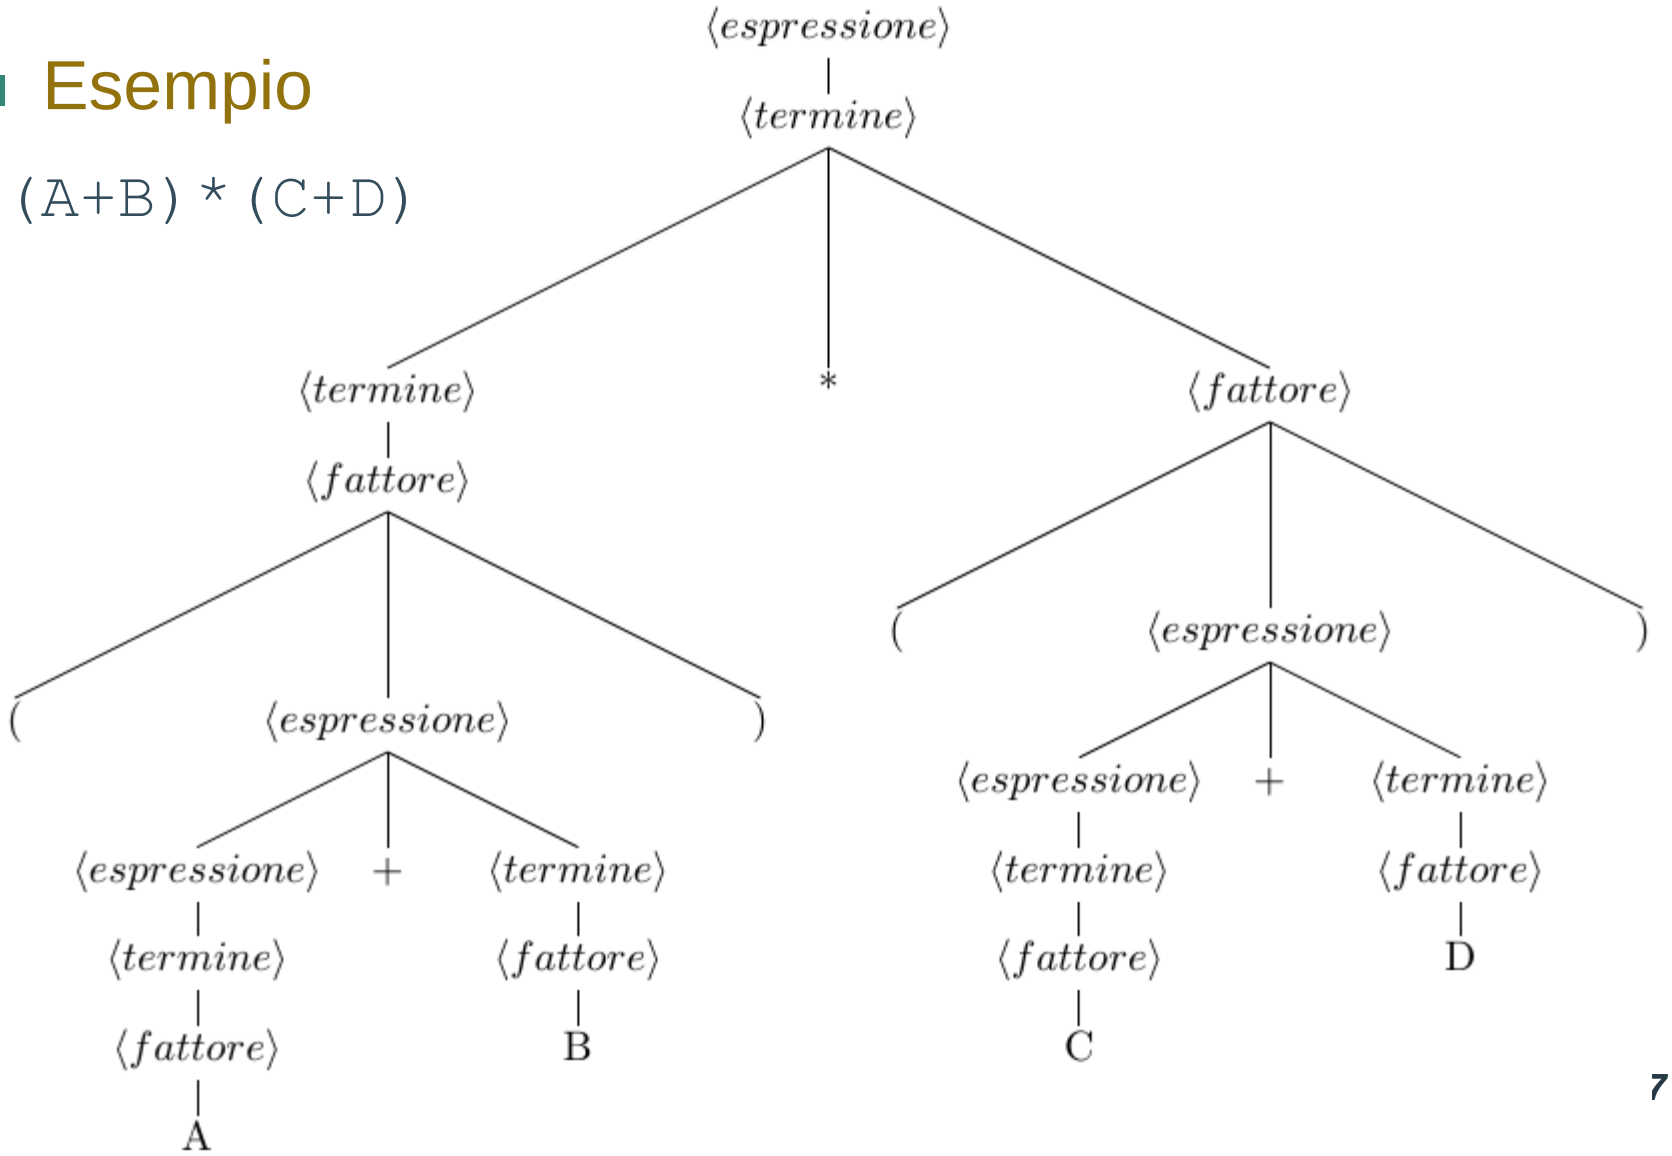

Analizzatore sintattico (parser)

- Esempio

```
x1:=a+bb*12;
x2:=a/2+bb*12;
```

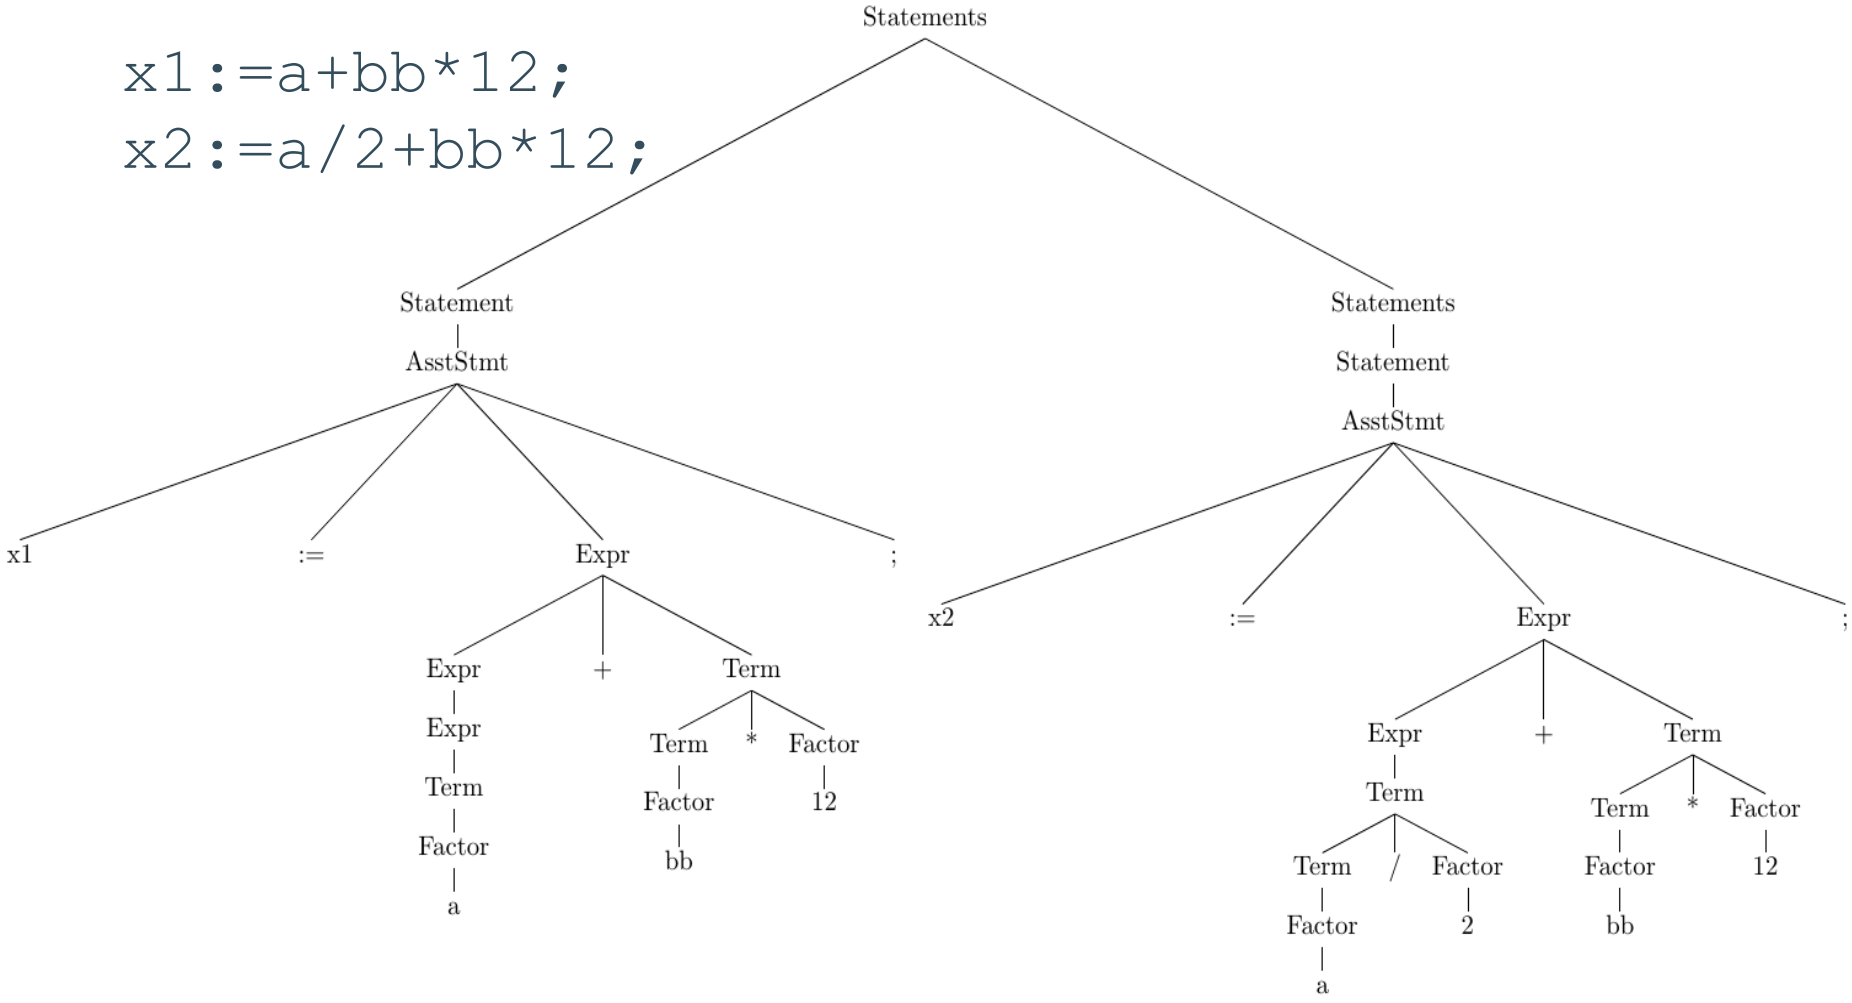

Analizzatore semantico

- Input: albero sintattico generato dal parser.
- Si compone di due fasi principali:
  1. Controlli statici (static checking).
  2. Generazione di una rappresentazione intermedia (IR)
- Output: albero arricchito con informazioni sui vincoli sintattici contestuali

Analizzatore semantico

- Input: albero sintattico generato dal parser.
- Si compone di due fasi principali:
  1. Controlli statici (static checking).
     Sono svolti vari controlli sui tipi, dichiarazioni, numero parametri funzioni, etc.

     Per l'espressione `(A+B)*(C+D)`, ad esempio, l'analizzatore semantico deve determinare quali azioni sono specificate dagli operatori aritmetici di addizione e moltiplicazione.

     Ad ogni token che corrisponde ad un identificatore di variabile è associato: tipo, luogo di dichiarazione, etc memorizzate nella tabella dei simboli.

     Quando riconosce il `+` od il `*` invoca allora una routine semantica che specifica le azioni da svolgere. Ad esempio, che gli operandi siano stati dichiarati, abbiano lo stesso tipo ed un valore.

Analizzatore semantico

- Input: albero sintattico generato dal parser.
- Si compone di due fasi principali:
  2. Generazione di una rappresentazione intermedia (IR)
     Spesso la parte di analisi semantica produce anche una forma intermedia di codice sorgente.

     Ad esempio può produrre il seguente insieme di quadruple per `(A+B)*(C+D)`:

     ```
     (+,A,B,T1)
     (+,C,D,T2)
     (*,T1,T2,T3)
     ```

     Od altri tipi di codice intermedio.

Analizzatore semantico

- Esempio: codice intermedio che rimuove dall'albero sintattico alcune delle categorie intermedie e mantiene solo la struttura essenziale (albero sintattico astratto).
  - Tutti i nodi sono token.
  - Le foglie sono operandi.
  - I nodi intermedi sono operatori.
- Spesso a valle dell'analizzatore semantico ci può essere un ottimizzatore del codice intermedio.

Analizzatore semantico

- Esempio:

```
x1:=a+bb*12;
x2:=a/2+bb*12;
```

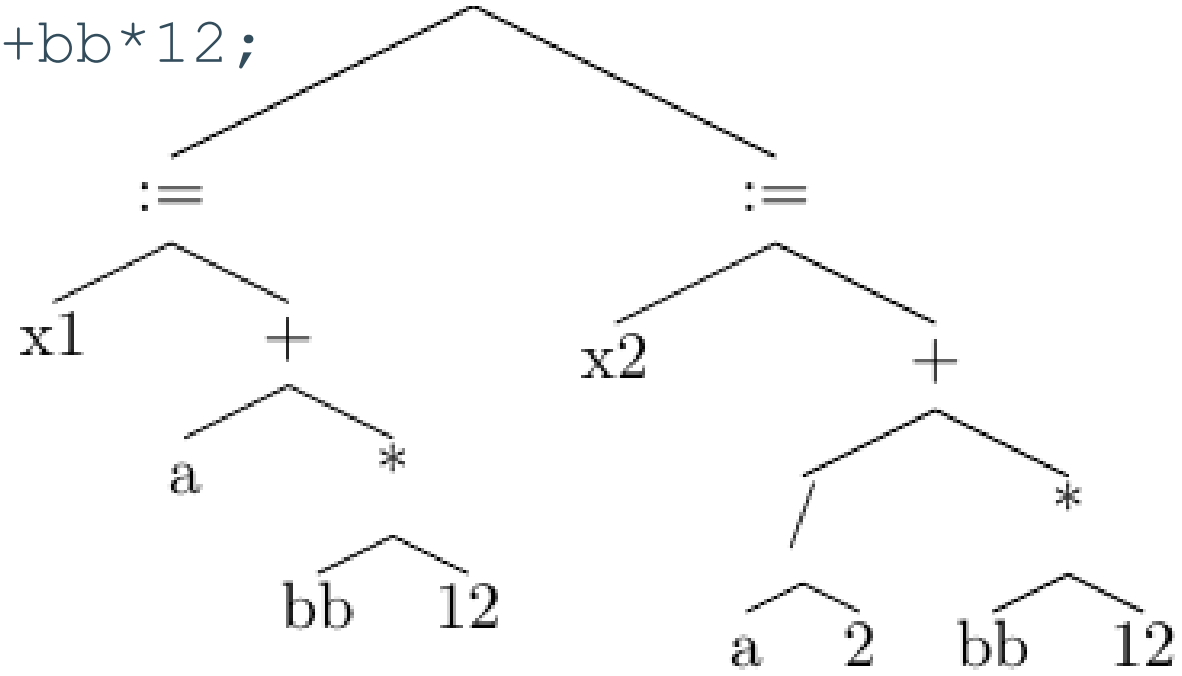

Analizzatore semantico

- Ottimizzazione del codice intermedio: propagazione di costanti
- Esempio

```
X:=3;
A:=B+X;
```

- Si può ottimizzare come:

```
X:=3;
A:=B+3;
```

evitando un accesso alla memoria.

Analizzatore semantico

- Ottimizzazione del codice intermedio: eliminazione di sotto-espressioni comuni
- Esempio

```
A:=B*C;
D:=B*C;
```

- Si trasforma in:

```
T:=B*C;
A:=T;
D:=T;
```

Analizzatore semantico

- Esempio

```
x1:=a+bb*12;
x2:=a/2+bb*12;
```

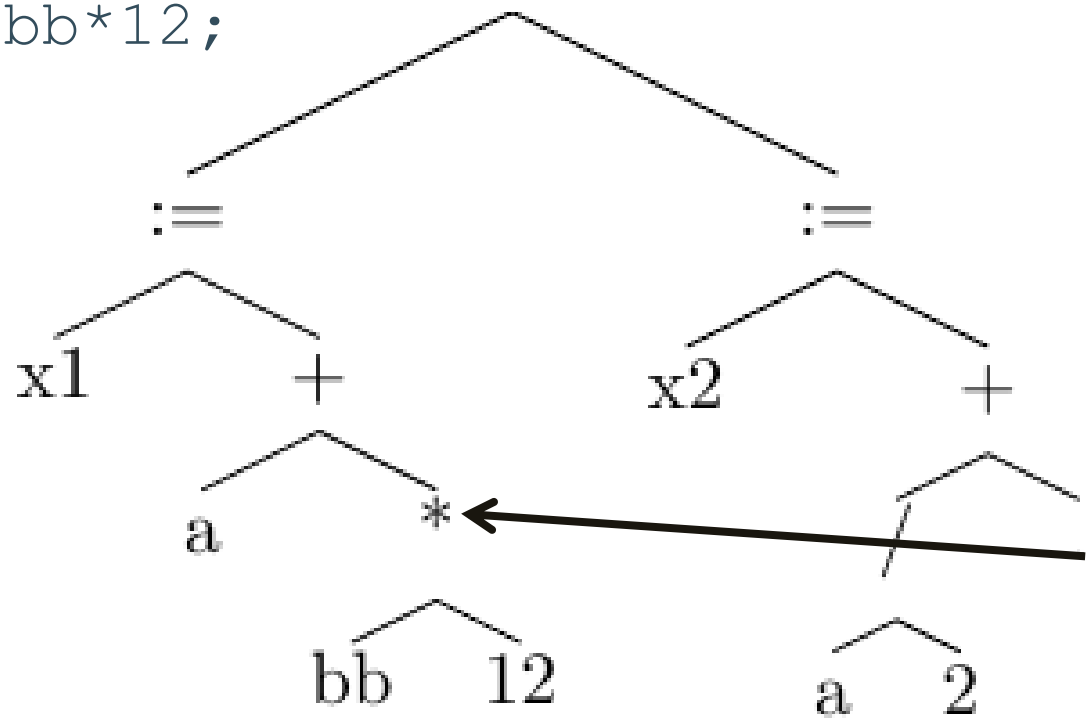

Analisi

- Verifica della correttezza lessicale, sintattica e semantica di un programma
  - Svolta in fase di compilazione;
  - Verifica che:
    - I simboli utilizzati siano legali, cioè appartengano all'alfabeto (analisi lessicale);
    - Le regole grammaticali siano rispettate (analisi sintattica);
    - I vincoli imposti dal contesto siano rispettati (analisi semantica).

- Esempio:

```
var A: integer;
…
if A then …
```

Errore!

Generatore di codice

- L'output dell'analizzatore semantico è passato al generatore di codice che trasla la forma intermedia in linguaggio assembler o macchina;
- Prima della generazione del codice oggetto ci sono delle fasi di preparazione:
  - Allocazione della memoria: può essere allocata staticamente oppure è uno stack o heap la cui dimensione cambia durante l'esecuzione;
  - Allocazione dei registri: poiché l'accesso ai registri è più rapido dell'accesso alle locazioni di memoria, i valori cui si accede più spesso andrebbero mantenuti nei registri.

Generatore di codice

- Esempio

```
x1:=a+bb*12;
x2:=a/2+bb*12;
```

- Potremmo pensare di allocare l'espressione `bb*12` al registro 1, ed una copia del valore di `a` al registro 2 assieme al valore `a/2`.
- Le variabili si potrebbero allocare sullo stack con `a` al top, e poi, nell'ordine, `bb`, `x1`, `x2`. Il registro S punta al top dello stack.
- Segue poi la vera e propria generazione di codice.

Generatore di codice

- Esempio

```
(A+B)*(C+D)

    (+,A,B,T1)
    (+,C,D,T2)
    (*,T1,T2,T3)
```

- Si possono produrre quindi le seguenti istruzioni assembler

```
LOADA A
LOADB B
STOREA T1
LOADA C
LOADB D
STOREA T2
LOADA T1
LOADB T2
MULT
STOREA T3
```

Generatore di codice

- Esempio

```
x1:=a+bb*12;
x2:=a/2+bb*12;
```

- Possiamo generare per una macchina di nostra invenzione il seguente codice
- Nota
  - (S), 1(S), 2(S), etc: accede al contenuto del top dello stack, ad una posizione successiva, due posizioni successive, etc.
  - @A: accede alla locazione il cui valore è puntato da A (indirizzamento indiretto).

Generatore di codice

- Esempio

```
x1:=a+bb*12;
x2:=a/2+bb*12;
```

- Possiamo generare per una macchina di nostra invenzione il seguente codice

```
PushAddr x2          Mette l'indirizzo di X2 nello stack
PushAddr x1          Mette l'indirizzo di X1 nello stack
Push bb              Mette bb nello stack
Push a               Mette a nello stack
Load 1(S),R1         Mette bb in R1
Mpy #12,R1           Mette bb*12 in R1
Load (S),R2          Mette a in R2
Store R2,R3          Copia a in R3
Add R1,R3            Mette a+bb*12 in R3
Store R3,@2(S)       Mette a+bb*12 in X1
Div #2,R2            Mette a/2 in R2
Add R1,R2            Mette a/2+bb*12 in R2
Store R2,@3(S)       Mette a/2+bb*12 in X2
```

Ottimizzatore di codice

- L'output del generatore di codice è passato in input all'ottimizzatore di codice, presente nei compilatori più sofisticati.
- Ottimizzazioni indipendenti dalla macchina: ad esempio la rimozione di istruzioni invarianti all'interno di un loop, fuori dal loop, etc.
- Ottimizzazioni dipendenti dalla macchina: ad esempio ottimizzazione dell'uso dei registri

Ottimizzatore di codice

- L'output del generatore di codice è passato in input all'ottimizzatore di codice, presente nei compilatori più sofisticati.
- Esempio: ottimizzazione del codice precedente

```
LOADA A
LOADB B
STOREA T1
LOADA C
LOADB D
STOREA T2
LOADA T1
LOADB T2
MULT
STOREA T3
```

```
LOADA A
LOADB B
STOREA T1
LOADA C
LOADB D
LOADB T1
MULT
STOREA T3
```

Passi di un compilatore

- Scanner e parser possono essere eseguiti in sequenza uno dopo l'altro, producendo prima tutti i token e poi l'analisi sintattica, oppure lo scanner è chiamato dal parser ogni volta che necessita un nuovo token.
- Nel primo caso lo scanner ha esaminato l'intero programma sorgente prima di passare il controllo al parser e quindi ha compiuto un intero passo separato.
- A volte il parser, l'analizzatore semantico ed il generatore di codice sono combinati in un singolo passo. Alcuni compilatori sono solo ad un passo, altri anche fino a 30!

Passi di un compilatore

- Abbiamo ignorato altri aspetti importanti della compilazione:
  1. Error Detection e Recovery;
  2. Le Tabelle dei Simboli prodotte dai vari moduli;
  3. La Gestione della Memoria implicata da alcuni costrutti del linguaggio di alto livello.
- Le fasi di più semplice progettazione, con un apparato formale ben sviluppato e quindi facilmente automatizzabili sono scanner e parser, mentre maggiore difficoltà si trova nella progettazione di analizzatori semantici, generatori ed ottimizzatori di codice.

Linking e Caricamento

- Il programma oggetto prodotto dal compilatore contiene una serie di riferimenti esterni (es. riferimenti a programmi di libreria, funzioni).
- I riferimenti esterni vengono risolti dal linker.
- Il programma è rilocabile: può essere allocato in diverse zone di memoria cambiando indirizzo `ind` (indirizzamento relativo).
- Fase di caricamento compiuta dal loader che assegna un valore numerico all'indirizzo `ind`, trasformando gli indirizzi relativi in assoluti.

Linking e Caricamento

- Esempio

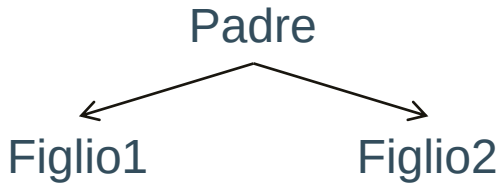

Padre	indirizzi relativi	da 0 a 300
Figlio1		da 0 a 120
Figlio2		da 0 a 150

Il linker riceve in ingresso questi tre moduli e genera un unico modulo con riferimento ad indirizzi contigui a partire da un indirizzo simbolico `ind`.

Ogni riferimento a moduli esterni viene sostitutito con l'indirizzo così calcolato.

Linking e Caricamento

- Esempio

Indirizzo	Contenuto	Commento
ind	Inizio Padre	
	…	
	salta ad ind + 301	rif. a Figlio1
	...	
	salta ad ind + 421	rif. a Figlio2
	…	
ind + 300	fine Padre	
ind + 301	inizio Figlio1	
	…	
ind + 420	fine Figlio1	
ind + 421	inizio Figlio2	
	…	
ind + 570	fine Figlio2	